像管理两种仓库一样，建模 HBM / HBF

把 LLM 访问落实到字节与地址，再按介质规则计算服务与排队

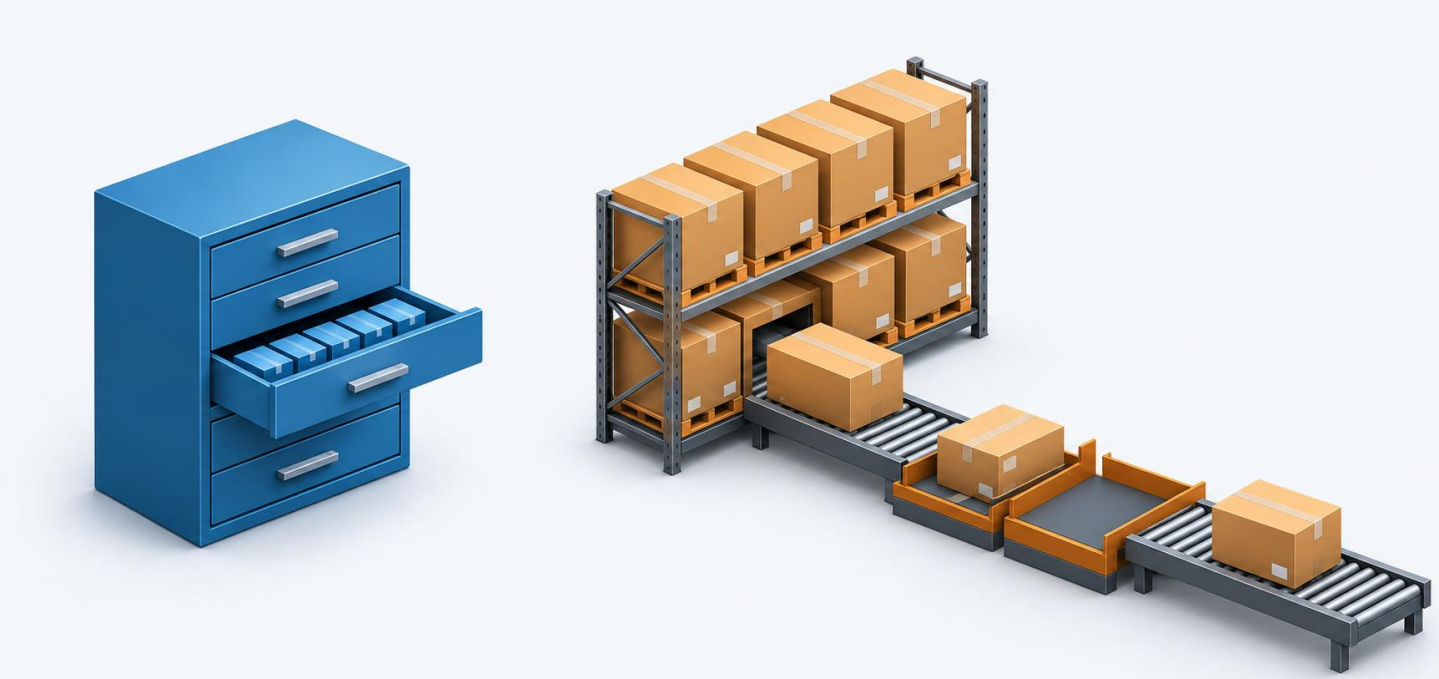
HBM

按行打开

按小块传输

bank 像柜子

row 像抽屉



HBF

整页读取

两槽暂存

page 像整箱

读缓冲像装卸位

共同原则：地址决定去哪里，状态与资源竞争决定何时完成

负载与配置 → 字节 / 地址 → 介质 + 排队 → Token 指标

HBM：抽屉是否已打开，决定命令成本

每个 bank 同时保持一行打开；行命中、关闭与冲突，需要不同命令链

字节请求 → 32 B burst → 地址映射到 channel / PC / bank / row

行命中
目标抽屉已开

RD → RL → DQ 数据传输

bank 关闭
先打开目标抽屉

ACT → tRCD → RD → RL → DQ 数据传输

行冲突
关旧抽屉，再开新的

PRE → tRP → ACT → tRCD → RD → RL → DQ 数据传输

还计算命令间隔、ACT 速率、读写切换和刷新；写请求对应 WR / WL

同样的字节数，行状态和排队也会改变访问延迟

HBF：整页取货，用双缓冲衔接三段服务

示例：16 die × 25 plane / 堆，4 KiB 页；连续页先分散到 die 通道，再轮换 plane



命中：跳过阵列与内部填充；仍要等缓存槽 ready 和 host 出口空闲

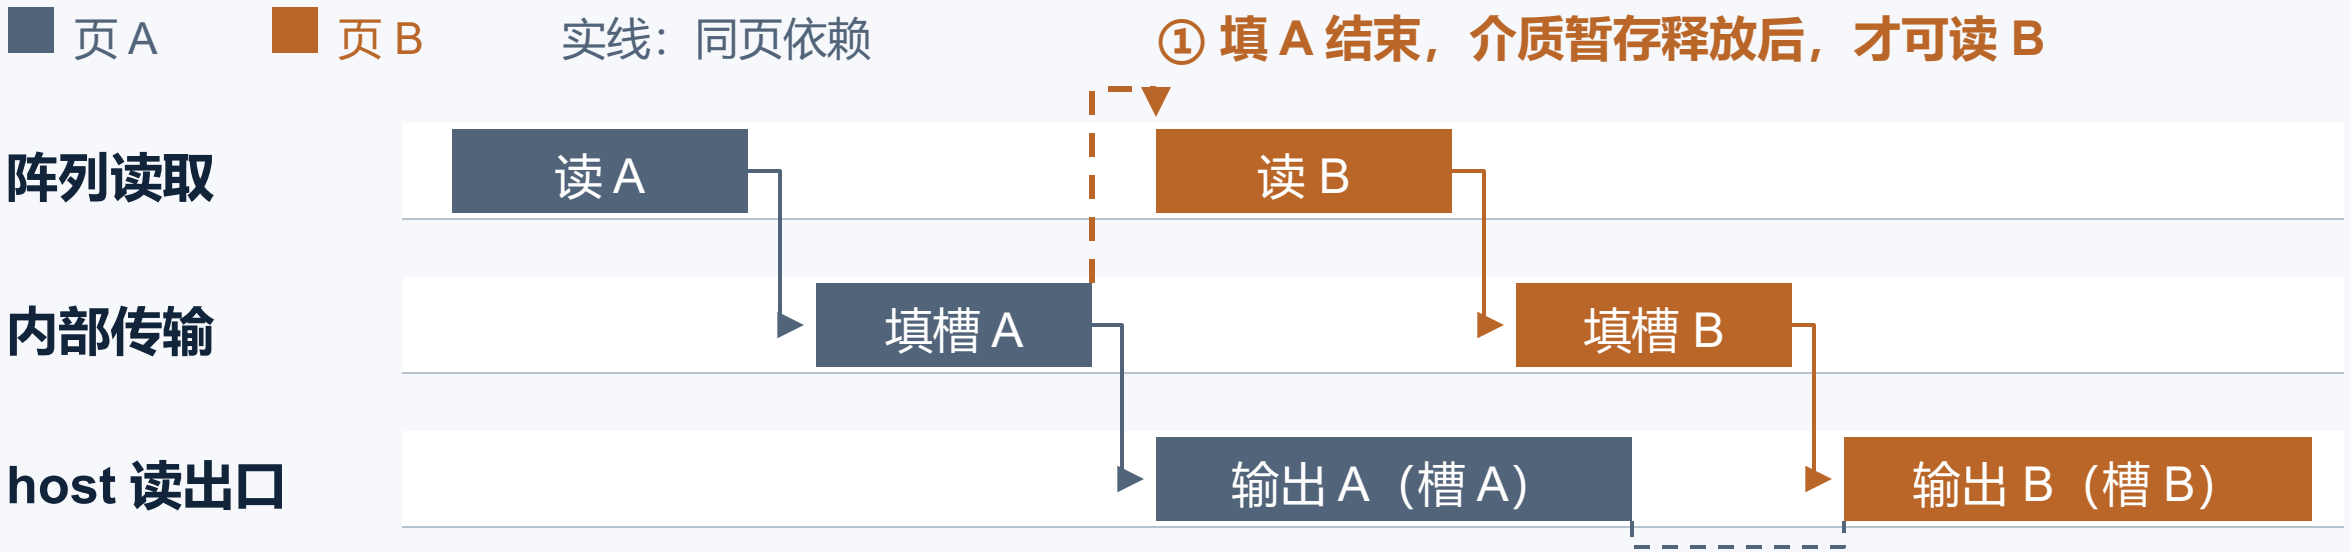
槽的两道门：填完才能读（ready）；旧读者结束才能覆盖（reader_end）

写入 host → 内部传输 → program 结束；部分页写可能另付 RMW

阵列读完还不算完成，必须等出口传输结束

同一条路要排队，不同资源可重叠

同一 plane；A / B 均未命中，各用一个初始空槽；共享内部通道和 host 读出口



② 可以重叠 读 B、填槽 B 可与输出 A 重叠；B 用另一个槽

③ 仍需等待 同一出口不能同时读 A / B；覆盖槽 A 还要等它的旧读者结束

同页按依赖串行；跨页仅在不同资源、且缓冲可用时重叠

算得出性能，也追得回原因

固定负载与统计口径，对比配置，并沿物理事件解释性能变化

HBM

行命中 / 冲突，命令计数

HBF

缓存命中，读页 / program

物理服务结果

完成时间 / 任务依赖

逻辑与物理字节

排队 / 各资源 busy

→

Token 吞吐

首 Token：TTFT

平均输出间隔：TPOT

指标口径要分开

服务跨度 service_ns ≠ 资源 busy ≠ 总耗时 makespan

服务跨度可以重叠；读资源占用，才能判断等待落在何处

参数分为标准参考、论文输入与研究假设；结果尚未经目标芯片实测校准